/*elice*/ Enterprise

코드와 원리

RAG 파이프라인의 코드를 해부합니다

10:30 ~ 11:20

앞에서 확인한 3가지

문서에 질문하면 정확한 답변이 나왔습니다

답변과 함께 출처(파일명 + 페이지)가 표시됐습니다

프롬프트 규칙을 바꾸니 답변 품질이 달라졌습니다

이제 "어떻게" 동작하는지 코드로 봅니다.

5단계 - 이번에는 코드로 봅시다

앞에서 질문했을 때, 이 5가지가 순서대로 일어났습니다

Step 1	Step 2	Step 3	Step 4	Step 5
질의 임베딩	**벡터DB 검색**	**프롬프트 조립**	**LLM 답변**	**답변 + 출처**
"용량이 얼마야?" → 벡터로 변환	비슷한 문서 조각 3개 찾기	"이 문서를 참고해서 답변하세요"	GPT-4o-mini가 문서 기반 답변 생성	답변 + 파일명 + 페이지 반환
		★ 오늘 핵심 1		★ 오늘 핵심 2

학습한 Step 1, 2 에 이어서 오늘 Step 3, 4, 5 를 진행합니다.

Step 3 - 프롬프트 조립

3단계 상세

벡터DB에서 검색된 문서 조각 3개

조각 1
"RF9000의 총 용량은 868L이며
냉장 524L, 냉동 344L..."

조각 2
"Triple Cooling System으로
독립 냉각을 지원하며..."

조각 3
"치수는 912×1825×920mm이고
중량은 135kg..."

+

사용자 질문

"RF9000의 총 용량은 얼마인가요?"

▼

조립된 최종 프롬프트

다음 문서를 참고하여 답하세요.
{context} ← 문서 3개가 여기에

질문: **{question}** ← 질문이 여기에

Step 4 - LLM 답변

조립된 프롬프트

문서 내용:
RF9000의 총 용량은
868L이며 냉장 524L,
냉동 344L...

질문:
RF9000의 총 용량은?

생성된 답변

RF9000의 총 용량은
868L입니다.

냉장실 524L,
냉동실 344L로
구성되어 있습니다.

핵심: LLM이 "자기가 아는 것"이 아니라 **"문서에서 찾은 내용"**을 근거로 답변합니다

Step 5 - 답변 + 출처

result 객체 구조

result['result']

→ "RF9000의 총 용량`은 868L입니다..."

result['source_documents']

→ 검색에 사용된 문서 조각들

각 조각에 metadata 포함:

source: "제품사양서.pdf"

page: 1

이것이 중요한 이유

답변의 근거를 확인할 수 있다

원본 문서를 바로 찾아갈 수 있다

잘못된 답변을 검증할 수 있다

return_source_documents=True
이 한 줄이 출처 반환을 켭니다

핵심 코드 5줄

핵심 슬라이드

```
from langchain.chains import RetrievalQA
from langchain_openai import ChatOpenAI

qa = RetrievalQA.from_chain_type(
    llm=ChatOpenAI(model="gpt-4o-mini", temperature=0),          ← Step 4 - LLM 선택
    chain_type="stuff",                                          ← Step 3 - 조립 방식
    retriever=vectorstore.as_retriever(search_kwargs={"k": 3}),  ← Step 2 - 검색기 설정
    return_source_documents=True                                 ← Step 5 - 출처 반환!
)
result = qa.invoke({"query": "RF9000의 총 용량은?"})
```

코드 해설 : LLM 파라미터

Step 4

```
llm=ChatOpenAI(model="gpt-4o-mini", temperature=0)
```

model = "gpt-4o-mini"

어떤 LLM을 쓸지 선택 - 비용과 성능의 균형

temperature = 0

0이면 가장 정확하고 일관된 답변 - 제조업 문서에는 0 권장

쉽게 말하면

"어떤 전문가에게 맡길까?"

gpt-4o-mini : 빠르고 저렴한 전문가
temperature=0 : "창의적으로 말고, 정확하게만 대답해"

코드 해설 : retriever 파라미터

Step 2

```
retriever=vectorstore.as_retriever(search_kwargs={"k": 3})
```

vectorstore.as_retriever()

Day2에서 만든 ChromaDB를 검색기로 변환.

"벡터DB에서 비슷한 문서를 찾아줘"

search_kwargs={"k": 3}

상위 3개 문서 조각을 가져옴.
우리 문서는 7페이지라 3개면 충분.

💡 k=30이면?

벡터DB에 15~20개 조각이 있는데
그 중 질문과 가장 비슷한 3개만 선택

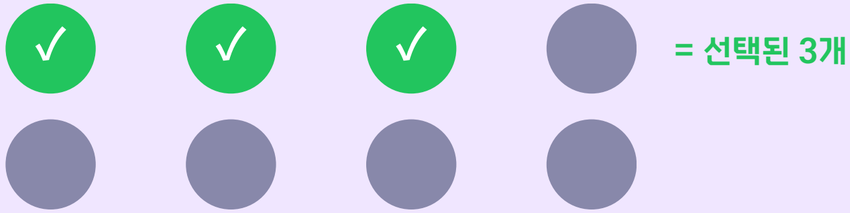

코드 해설 : chain_type

Step 3

```
chain_type="stuff"
```

stuff = "전부 넣기"

검색된 문서 조각 3개를 프롬프트에 전부 넣는 방식
우리 문서는 7페이지(사양서 4 + 시험성적서 3)라 전부 넣어도 충분합니다.
이것만 기억하세요. 나머지 방식은 참고자료에 있습니다.

참고: 3가지 방식

stuff 전부 넣기	★ 이것만
map_reduce 나눠서 요약	
refine 하나씩 정제	

"3가지가 있는데, 우리 문서는 짧으니 stuff면 충분합니다. 이것만 기억하세요."

코드 해설 : 출처 반환 스위치

Step 5 담당

```
return_source_documents=True
```

True (켜기) ✅

답변 + 출처 문서 반환
→ 파일명, 페이지 번호 확인 가능
→ 제조업 보고서에 활용 가능

False (끄기) ❌

답변만 반환
→ 근거를 확인할 수 없음
→ "이 숫자 어디서 나왔어?" 답 못함

제조업에서는 항상 True. 근거 없는 답변은 쓸 수 없습니다.

커스텀 프롬프트: 왜 필요한가?

블록1에서 기본과 커스텀의 차이를 봤습니다. 왜 달랐을까요?

기본 프롬프트 (LangChain 기본값)

Q: "RF9000 소비전력은?"

A: "RF9000의 소비전력은
36W입니다. 이 냉장고는
Triple Cooling System을
채택하고 있으며
에너지효율 1등급..."

장황하게 답변

커스텀 프롬프트 (규칙 적용)

Q: "RF9000 소비전력은?"

A: "RF9000의 소비전력은
36W입니다.
(제품사양서 p.2)"

간결 + 단위 포함

차이를 만든 건 **프롬프트에 넣은 "규칙" 3줄**입니다.

PromptTemplate — RAG 버전

2주차에 배운 PromptTemplate과 동일합니다. 변수가 다를 뿐.

```
custom_prompt = PromptTemplate(
    template="""
다음 문서 내용을 참고하여 질문에 답하세요.

문서 내용:
{context}

질문: {question}

답변 규칙:
"""
    input_variables=["context", "question"]
```

{context}

검색된 문서 조각이
자동으로 들어가는 자리

{question}

사용자 질문이
자동으로 들어가는 자리

2주차의 {input}이 RAG에서는 {context}와 {question}으로 나뉩니다

프롬프트 규칙 3가지

이 규칙이 답변의 품질을 결정합니다

1

문서에 있는 정보만 사용하세요

LLM이 자기 지식으로 답하는 걸 막습니다. → 할루시네이션 방지의 첫 번째 방어선

2

문서에 없으면 "해당 정보를 찾을 수 없습니다"

모르면 모른다고 말하게 합니다. → 거짓 답변보다 "모른다"가 안전합니다

3

수치를 인용할 때는 단위를 반드시 포함하세요

"868"이 아니라 "868L"로 답하게 합니다. → 제조업에서 단위 없는 숫자는 의미가 없습니다

오후 실습에서 이 규칙을 직접 코드에 넣어봅니다

BRAINSTORMING

우리 업무에 맞는 규칙을 만든다면?

조별로 1개씩 → 오후 실습에서 직접 코드에 넣어봅니다!

예시

› "안전 관련 수치는 반드시 시험성적서 출처를 명시하세요"
› "에러코드 설명 시 조치방법도 함께 답하세요"
› "한국어로만 답변하세요"
› "표 형식으로 정리해서 답하세요"

핵심 정리

1. RAG 5단계 코드 확인 (RetrievalQA 5줄)
2. 코드의 역할 이해
3. 커스텀 프롬프트로 인한 답변 품질 변화 확인
4. 규칙 아이디어 생성 (오후 실습 예정)